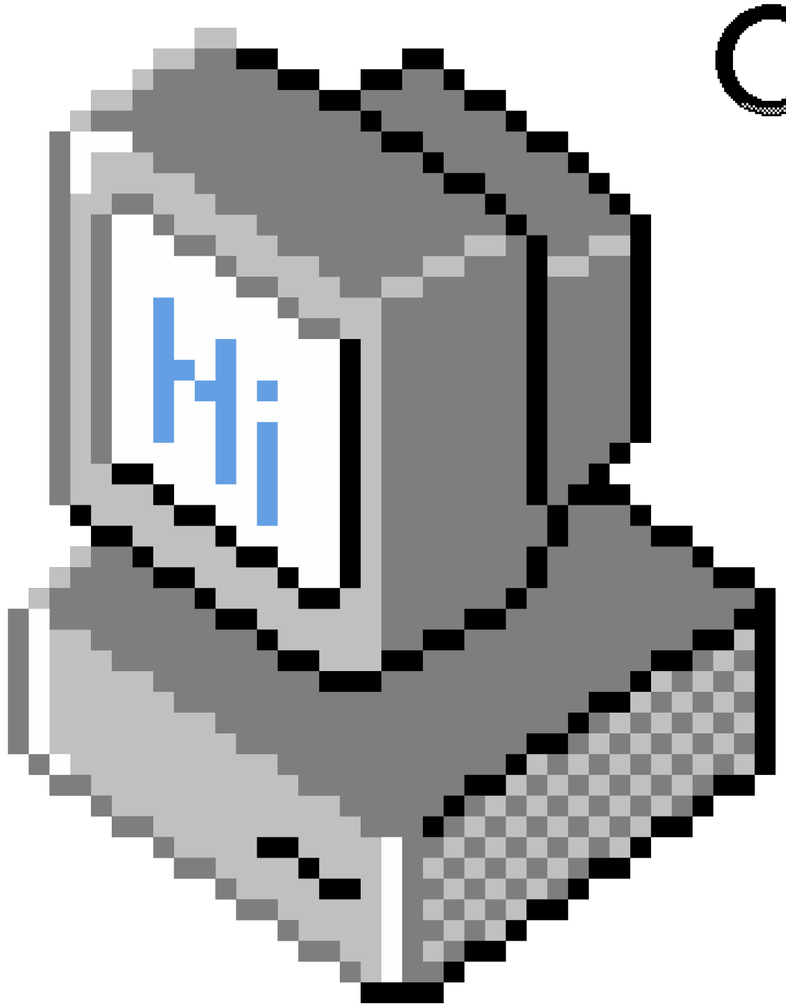




OCR TRANSCRIPT

INTELLIGENT SYSTEM DEVELOPMENT

Presented by loso group

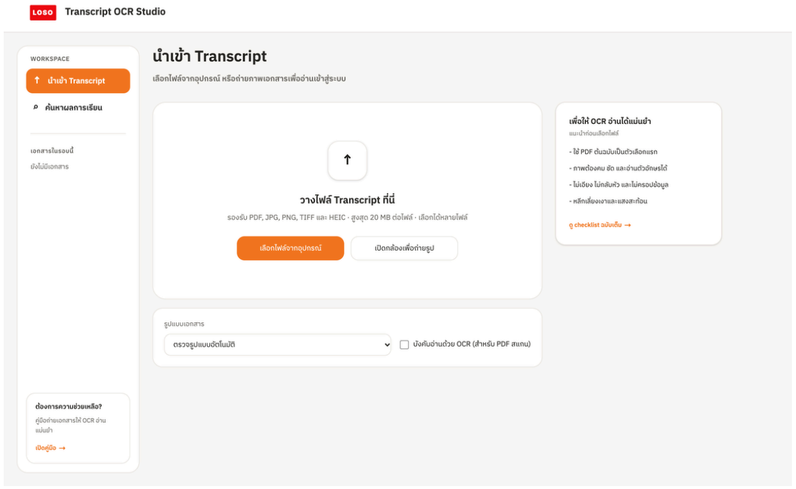
MEMBER

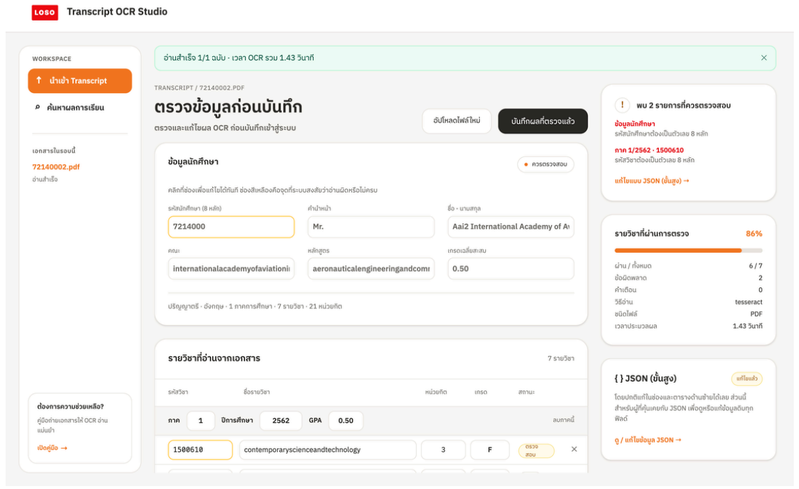
67070005
นายกวีวัฒน์ สานนท์กุลวัฒน์

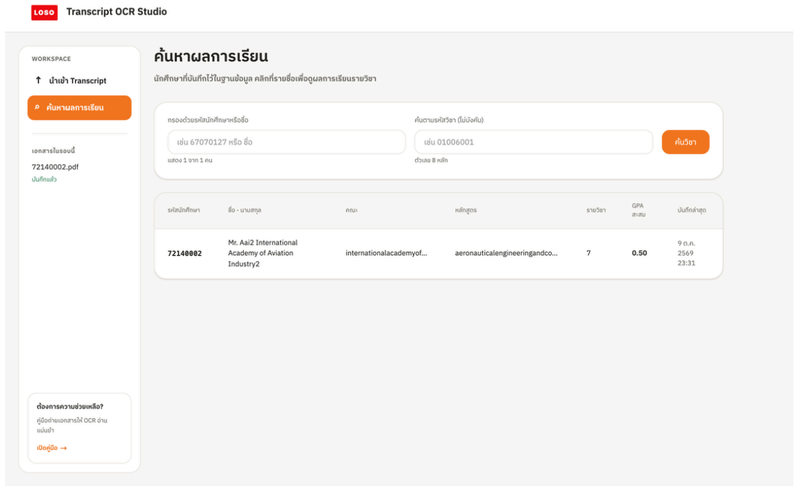
67070124
นายภคพล โพธิวร

67070127
นายภัทรพล เพ็ชรรัตน์

อัปโหลดหรือถ่ายรูป ตรวจแก้ในหน้าเดียว แล้วบันทึกและค้นหาได้







ขั้น	ผู้ใช้ทำ	ระบบทำ
นำเข้า	ลากไฟล์ / เลือกหลายไฟล์ / ถ่ายด้วยกล้อง	ตรวจชนิดและขนาดไฟล์ แล้วส่งอ่าน
ตรวจและแก้	แก้ในช่องได้ทันที	ตรวจซ้ำอัตโนมัติ ช่องที่สงสัยเป็นสีเหลือง
บันทึก	กด "บันทึกผลที่ตรวจแล้ว"	เก็บลง SQLite
ค้นหา	ค้นตามรหัสนักศึกษา / ชื่อ / รหัสวิชา	แสดงรายชื่อ และรายละเอียดรายภาค





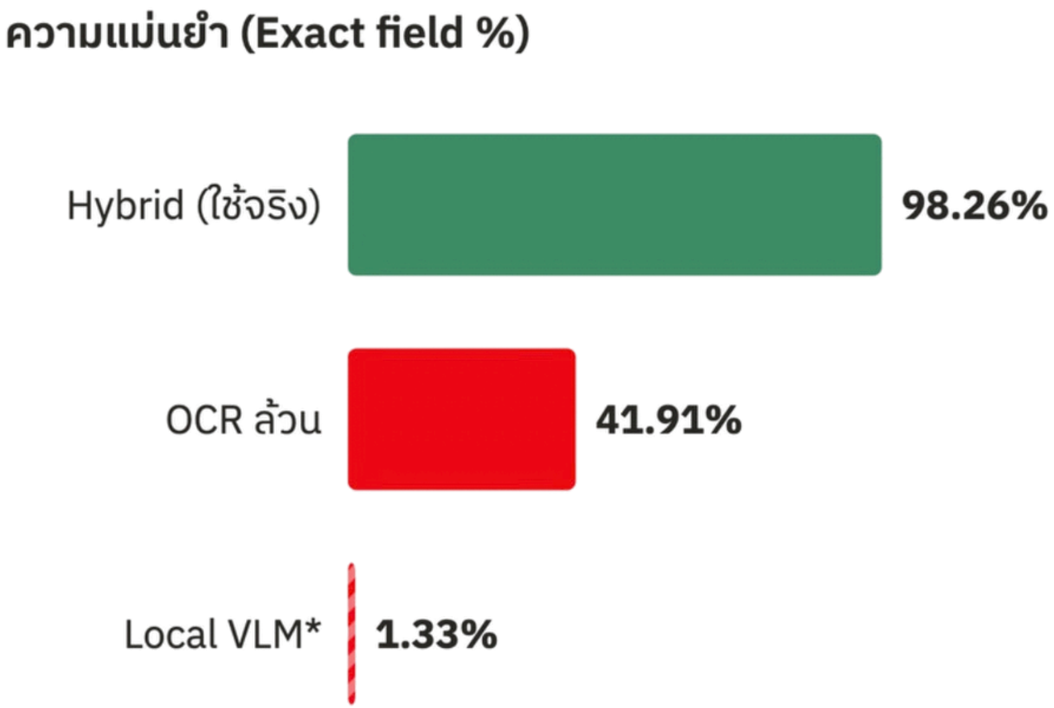


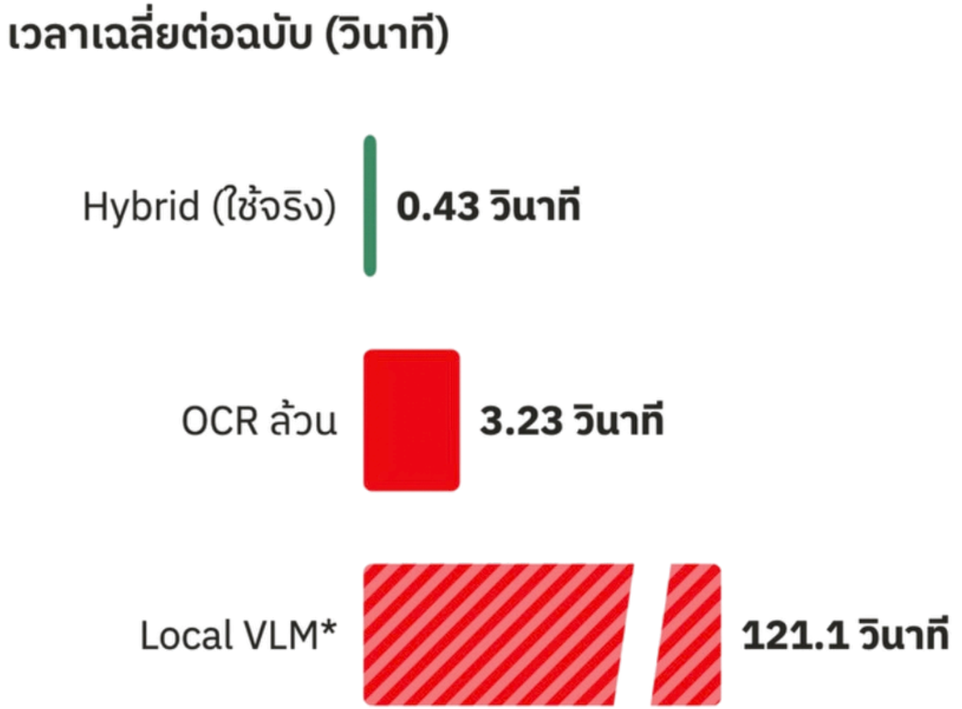


ไฟล์ที่เข้า	เส้นทาง	เครื่องมือ	เวลาเฉลี่ย (วัดแล้ว)
PDF ผ่านเกณฑ์ข้อความฝัง	ใช้ข้อความฝังทันที	pdftotext	0.12 วินาที
PDF ไม่ผ่านเกณฑ์	เรนเดอร์ แล้ว OCR	pdftoppm + Tesseract	5.10 วินาที
ภาพทั่วไป (PNG/JPG ...)	แก้เรขาคณิต → อ่านตามรูปแบบ → OCR	OpenCV + Tesseract	8.87 วินาที (PNG)
ภาพถ่ายมือถือ	แก้เรขาคณิต → ตัวอ่านที่ฝึกเพิ่ม	OpenCV + Tesseract eng_phone	27.54 วินาที (รายงานเดิม)



เลือก Hybrid เพราะแม่นถึง 98% และเร็วกว่า OCR ล้วนราว 7 เท่า

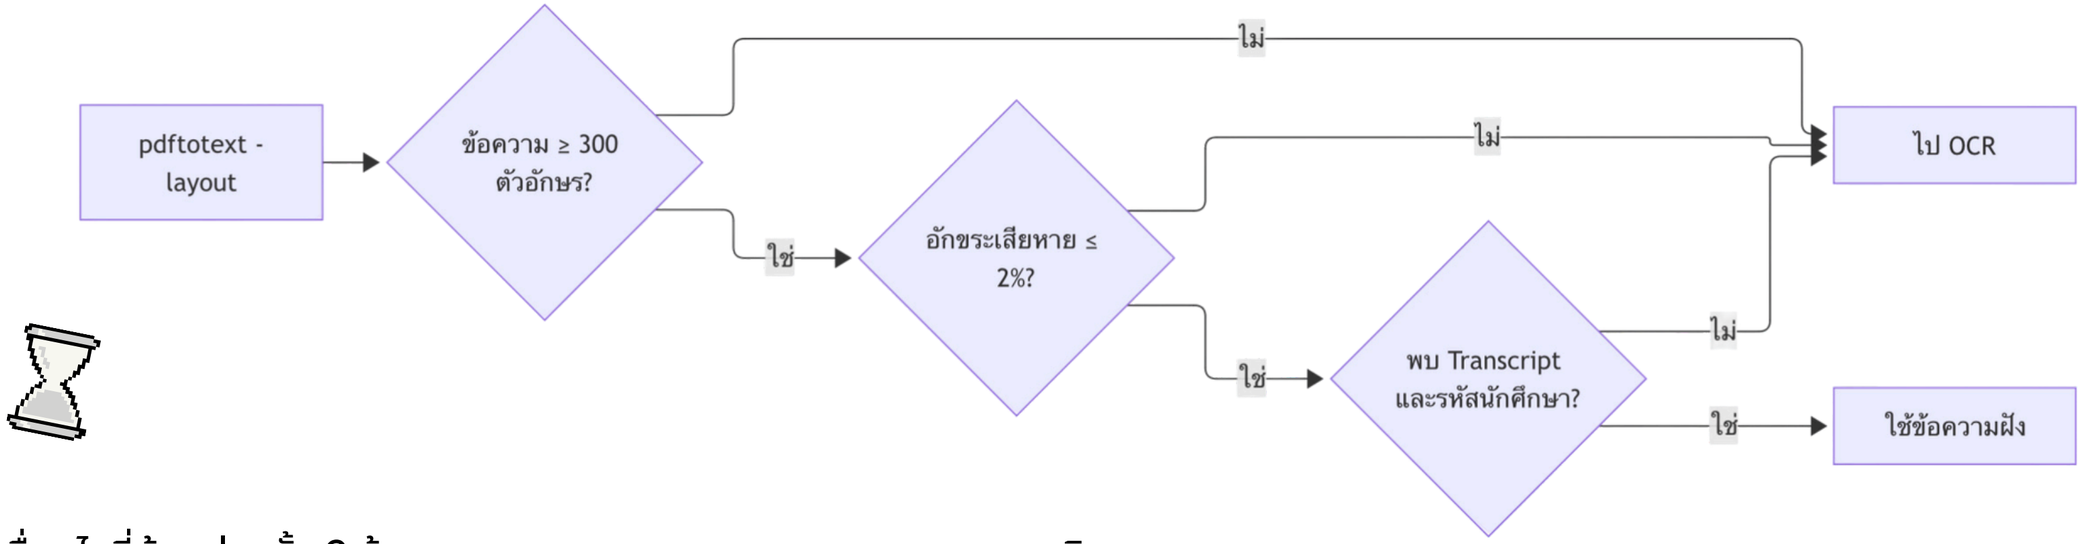




* Hybrid และ OCR ล้วนวัดบน PDF ชุดเดียวกัน 8 ฉบับ · Local VLM วัดบนภาพ PNG 4 ฉบับ (สำเร็จ 1/4 ฉบับ, ถูก 1/75 ฟิลด์) ไม่ใช่ชุดเดียวกัน

ที่มา: model/reports/route-comparison-dev.json, vlm-dev.json

บาง PDF มีข้อความฝังแต่ถอดออกมาเป็นอักขระเพี้ยน จึงต้องตรวจคุณภาพก่อนเชื่อถือ



เงื่อนไขที่ต้องผ่านทั้ง 3 ข้อ

#	เงื่อนไข	ค่า	ถ้าไม่ผ่าน
1	ความยาวข้อความ	≥ 300 ตัวอักษร	ไป OCR
2	อักขระเสียหาย	≤ 2%	ไป OCR
3	พบคำหลัก	Transcript และรหัสนักศึกษา	ไป OCR

ผลจริง

ผล	จำนวนที่วัด	เวลา
ผ่านเกณฑ์ (3 รูปแบบ: ป.ตรีไทย, บัณฑิตไทย/อังกฤษ)	6 ฉบับ	0.04–0.62 วินาที (เฉลี่ย 0.12)
ไม่ผ่าน → OCR (ป.ตรีอังกฤษ ฟอนต์ Type 3 ไม่มี Unicode ข้อความเพี้ยนเป็น ÿ)	2 ฉบับ	3.2–7.5 วินาที (เฉลี่ย 5.10)

ถ้าอ่านข้อความฝังไม่ได้ ระบบเรนเดอร์เป็นภาพแล้ว OCR ด้วย Tesseract

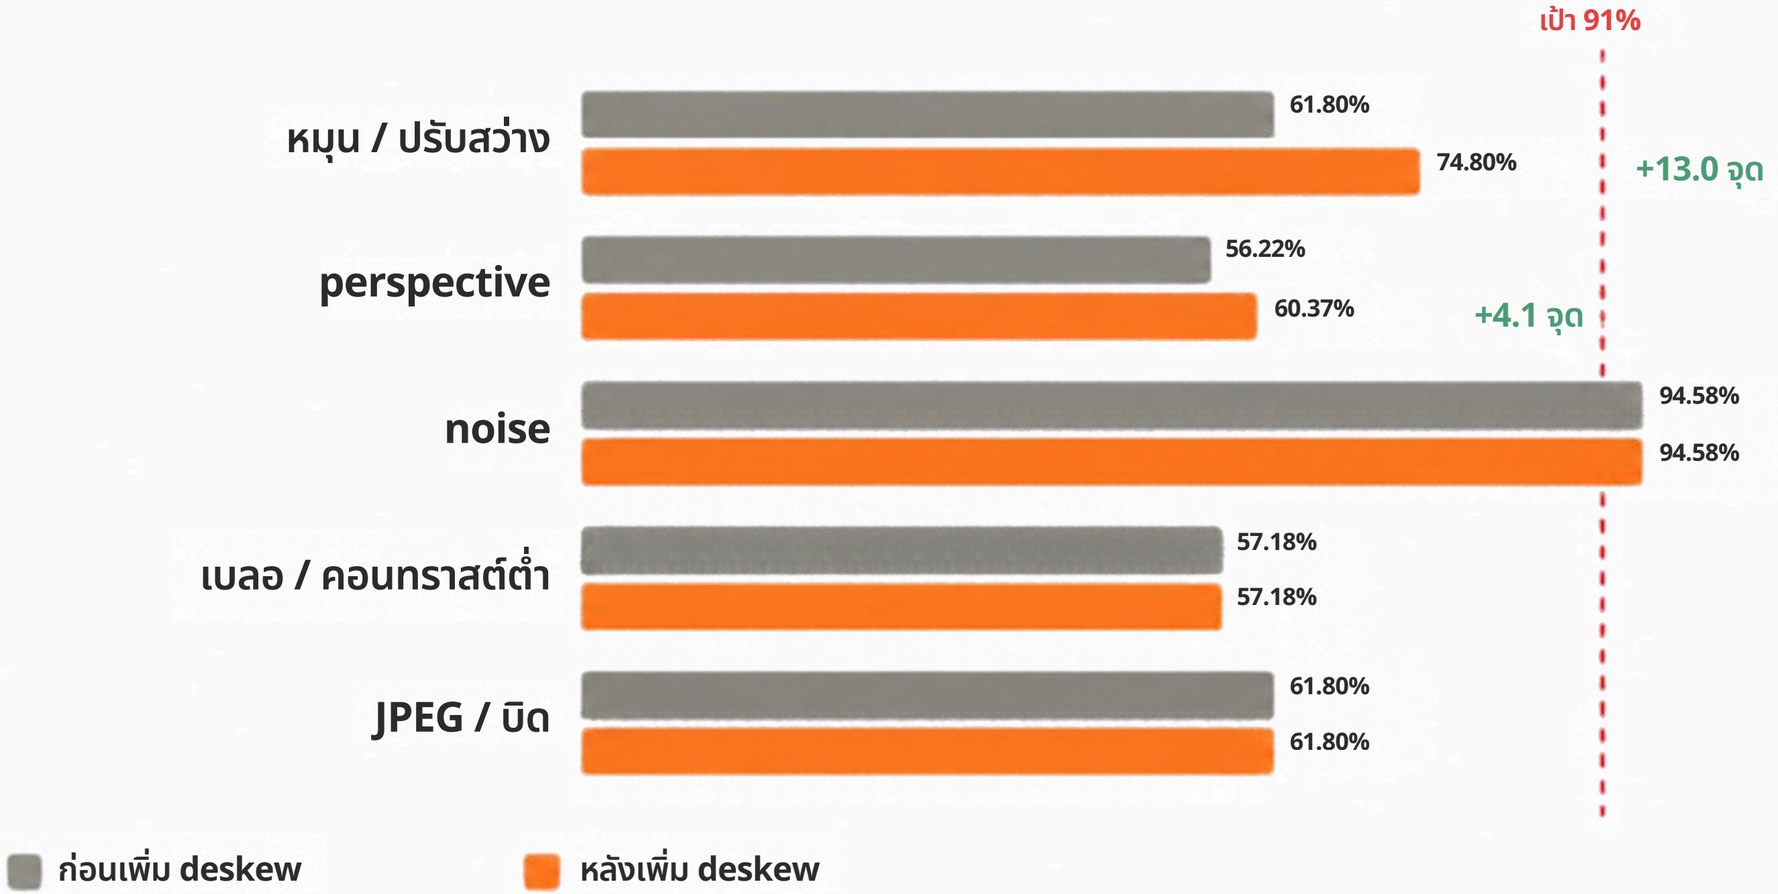


พารามิเตอร์	ค่า	ที่มา / เหตุผลที่ระบุไว้
เรนเดอร์ PDF เป็นภาพ	250 DPI	Poppler pdftoppm
โหมดจัดหน้าของ Tesseract	--psm 6	โหมดบล็อกข้อความ
ภาษา	eng → สำรอง tha+eng	อังกฤษอย่างเดียวอ่านตัวอักษรเกรด (A, B+ ...) สม่ำเสมอกว่า · สำรองเมื่อไม่พบหัวเอกสารอังกฤษ
ขยายภาพ	2× ถ้ากว้าง < 2000 px	ภาพเล็กก่อน OCR (LANCZOS)



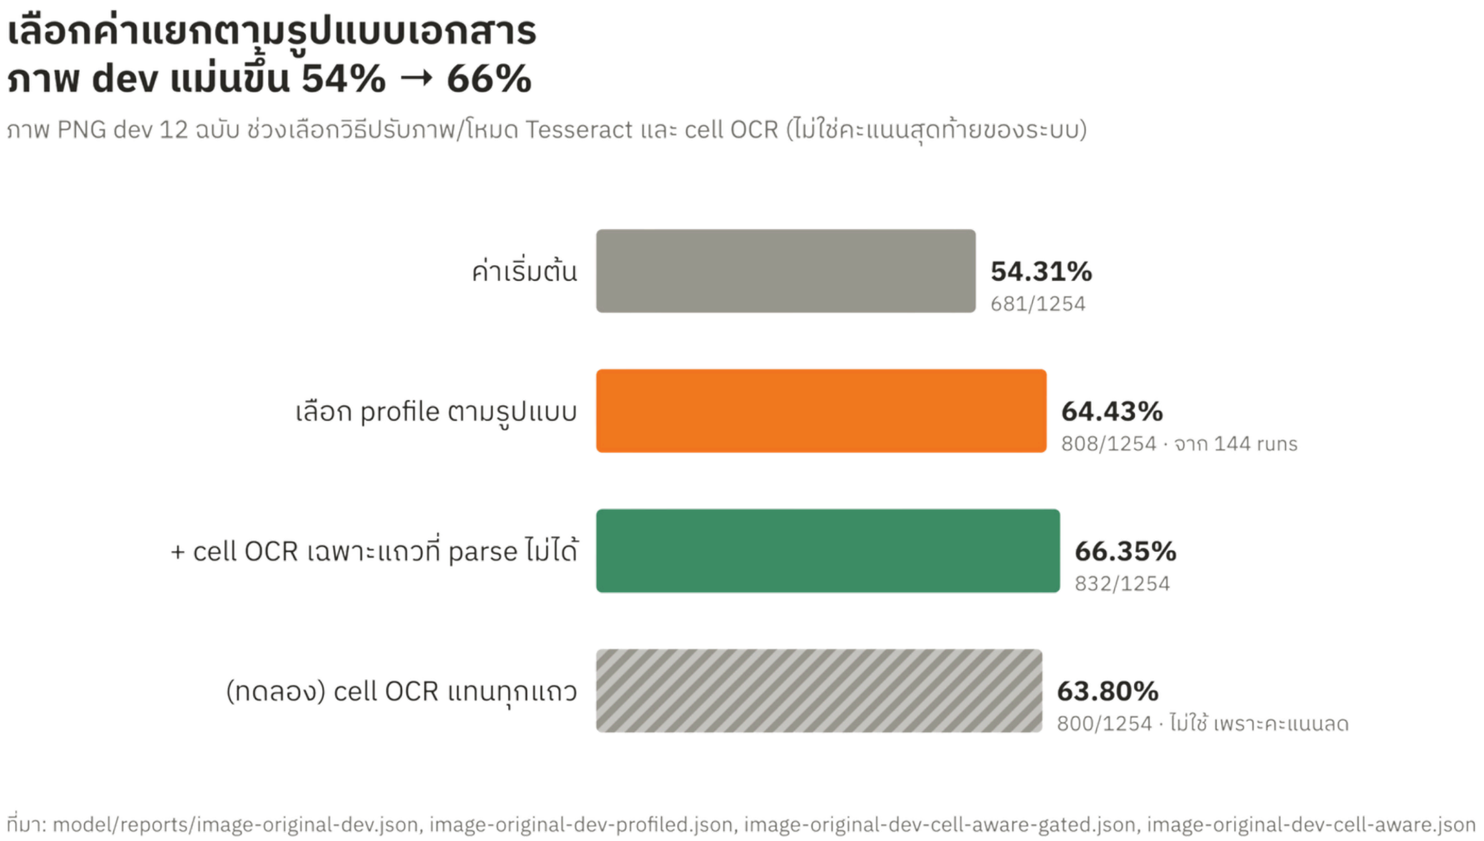


ภาพถ่ายต้องถูกจัดให้ตรงก่อนอ่าน เพิ่ม deskew แล้วภาพหมุน สว่างแม่นขึ้น



ที่มา: model/reports/augmented-dev-no-deskew-full-20261004.json, augmented-dev-deskew-full-20261004.json · แลกกินเวลาสูงสุด 28.9 → 44.3 วินาที/ภาพ

อ่านตารางตามโครงสร้างของแต่ละรูปแบบเอกสาร



ที่มา: model/reports/image-original-dev.json, image-original-dev-profiled.json, image-original-dev-cell-aware-gated.json, image-original-dev-cell-aware.json

รูปแบบเอกสาร	การปรับภาพ	Tesseract PSM
ปริญญาตรี ไทย	original	4
ปริญญาตรี อังกฤษ	sharpen	6
บัณฑิตศึกษา ไทย	sharpen	4
บัณฑิตศึกษา อังกฤษ	autocontrast	4

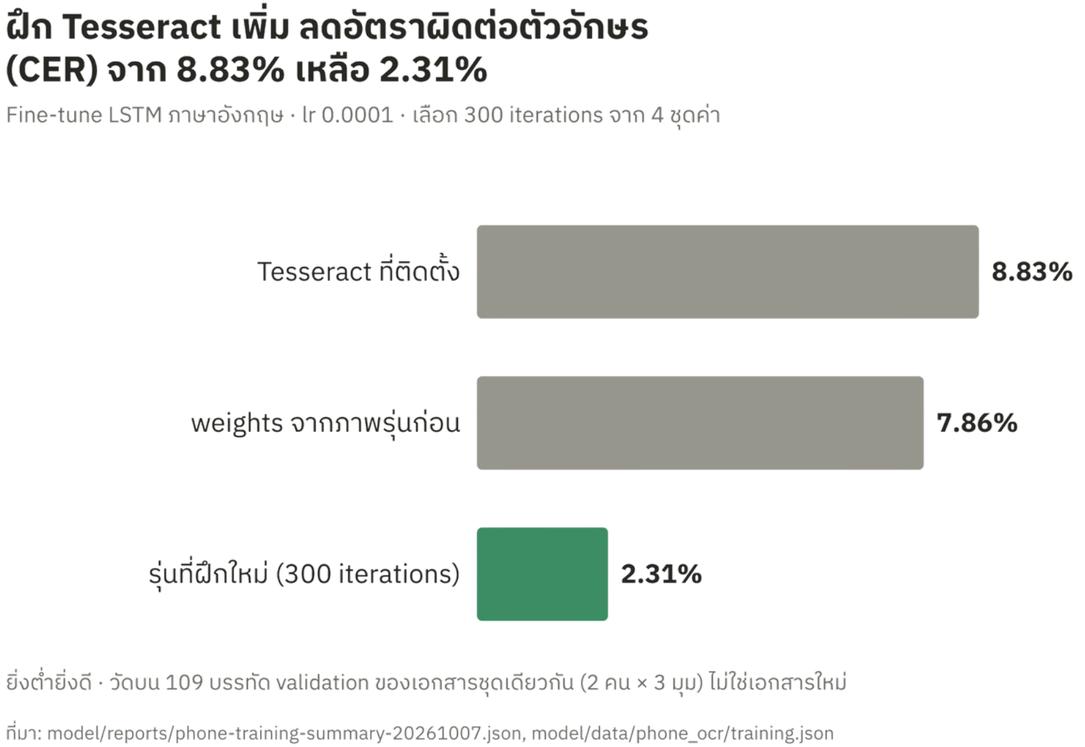
แต่ละรูปแบบมีค่าที่ดีที่สุดต่างกัน จึงไม่ใช้ค่าเดียวกับทุกไฟล์





ฝึก Tesseract เพิ่มจากภาพมือถือ

Iterations	Learning rate	CER (validation)	ผลการเลือก
100	0.0001	6.17%	
300	**0.0001**	**2.31%**	**เลือกใช้**
600	0.0001	2.49%	
300	0.0003	2.31%	เท่ากับค่าที่เลือก



CER ยิ่งต่ำยิ่งดี • ค่าต่ำสุด 2.31% พบใน 2 ชุดค่า
วัดบน validation 109 บรรทัดของเอกสารชุดเดียวกัน ยังไม่ใช่ผลทดสอบกับเอกสารใหม่

แปลงเป็น JSON แล้วตรวจกฎ

กฎ	เงื่อนไข	ข้อความที่ผู้ใช้เห็น
รหัสนักศึกษา	ตัวเลข 8 หลัก	รหัสนักศึกษาต้องเป็นตัวเลข 8 หลัก
รหัสวิชา	ตัวเลข 8 หลัก	รหัสวิชาต้องเป็นตัวเลข 8 หลัก
หน่วยกิต	จำนวนเต็ม 0–30	หน่วยกิตต้องเป็นจำนวนเต็ม 0-30
เกรด	อยู่ในรายการที่รองรับ	เกรดไม่อยู่ในรายการที่รองรับ
GPA	0.00–4.00	GPA ต้องอยู่ระหว่าง 0.00-4.00

กฎตรวจ และข้อความที่ผู้ใช้เห็น (จาก validate.py)

LOSO **Transcript OCR Studio**

WORKSPACE

↑ นำเข้า Transcript

ค้นหาผลการเรียน

เอกสารในรอบนี้

72140002.pdf

อ่านสำเร็จ

ต้องการความช่วยเหลือ?

คู่มือถ่ายเอกสารให้ OCR อ่านแม่นยำ

เปิดคู่มือ →

อ่านสำเร็จ 1/1 ฉบับ · เวลา OCR รวม 1.43 วินาที ×

TRANSCRIPT / 72140002.PDF

ตรวจข้อมูลก่อนบันทึก

ตรวจและแก้ไขผล OCR ก่อนบันทึกเข้าสู่ระบบ

อัปโหลดไฟล์ใหม่ | บันทึกผลที่ตรวจแล้ว

ข้อมูลนักศึกษา

ควรตรวจสอบ

คลิกที่ช่องเพื่อแก้ไขได้ทันที ช่องสีเหลืองคือจุดที่ระบบสงสัยว่าอ่านผิดหรือไม่ครบ

รหัสนักศึกษา (8 หลัก)	คำนำหน้า	ชื่อ - นามสกุล
7214000	Mr.	Aai2 International Academy of A

คณะ	หลักสูตร	เกรดเฉลี่ยสะสม
internationalacademyofaviationi	aeronauticalengineeringandcom	0.50

ปริญญาตรี · อังกฤษ · 1 ภาคการศึกษา · 7 รายวิชา · 21 หน่วยกิต

รายวิชาที่อ่านจากเอกสาร

7 รายวิชา

รหัสวิชา	ชื่อรายวิชา	หน่วยกิต	เกรด	สถานะ	
ภาค 1 ปีการศึกษา 2562 GPA 0.50					ลบภาคนี้
1500610	contemporaryscienceandtechnology	3	F	ตรวจสอบ	×

! **พบ 2 รายการที่ควรตรวจสอบ**

ข้อมูลนักศึกษา
รหัสนักศึกษาต้องเป็นตัวเลข 8 หลัก

ภาค 1/2562 · 1500610
รหัสวิชาต้องเป็นตัวเลข 8 หลัก

แก้ไขแบบ JSON (ขั้นสูง) →

รายวิชาที่ผ่านการตรวจ 86%

ผ่าน / ทั้งหมด	6 / 7
ข้อผิดพลาด	2
คำเตือน	0
วิธีอ่าน	tesseract
ชนิดไฟล์	PDF
เวลาประมวลผล	1.43 วินาที

{ } JSON (ขั้นสูง)

แก้ไขแล้ว

โดยปกติแก้ในช่องและตารางด้านซ้ายได้เลย ส่วนนี้สำหรับผู้ที่คุ้นเคยกับ JSON เพื่อดูหรือแก้ข้อมูลดิบทุกฟิลด์

ดู / แก้ไขข้อมูล JSON →

ชุดข้อมูลและ metrics

Metric	ความหมาย	เป้า
Exact field accuracy	ฟิลด์ตรงเฉลยเป๊ะ, ฟิลด์ที่หายนับว่าผิด	> 91%
Row F1	แถวรายวิชาที่หาย/เกิน	รายงานประกอบ
CER	อัตราผิดต่อตัวอักษร (ใช้ตอนฝึก OCR ภาพมือถือ)	-
Latency	เวลาต่อฉบับ	< 30 วินาที เฉลี่ย

ทดสอบกับ transcript จริง 48 ฉบับ แยก dev 35 test 12

การแบ่งชุดข้อมูลระดับเอกสาร

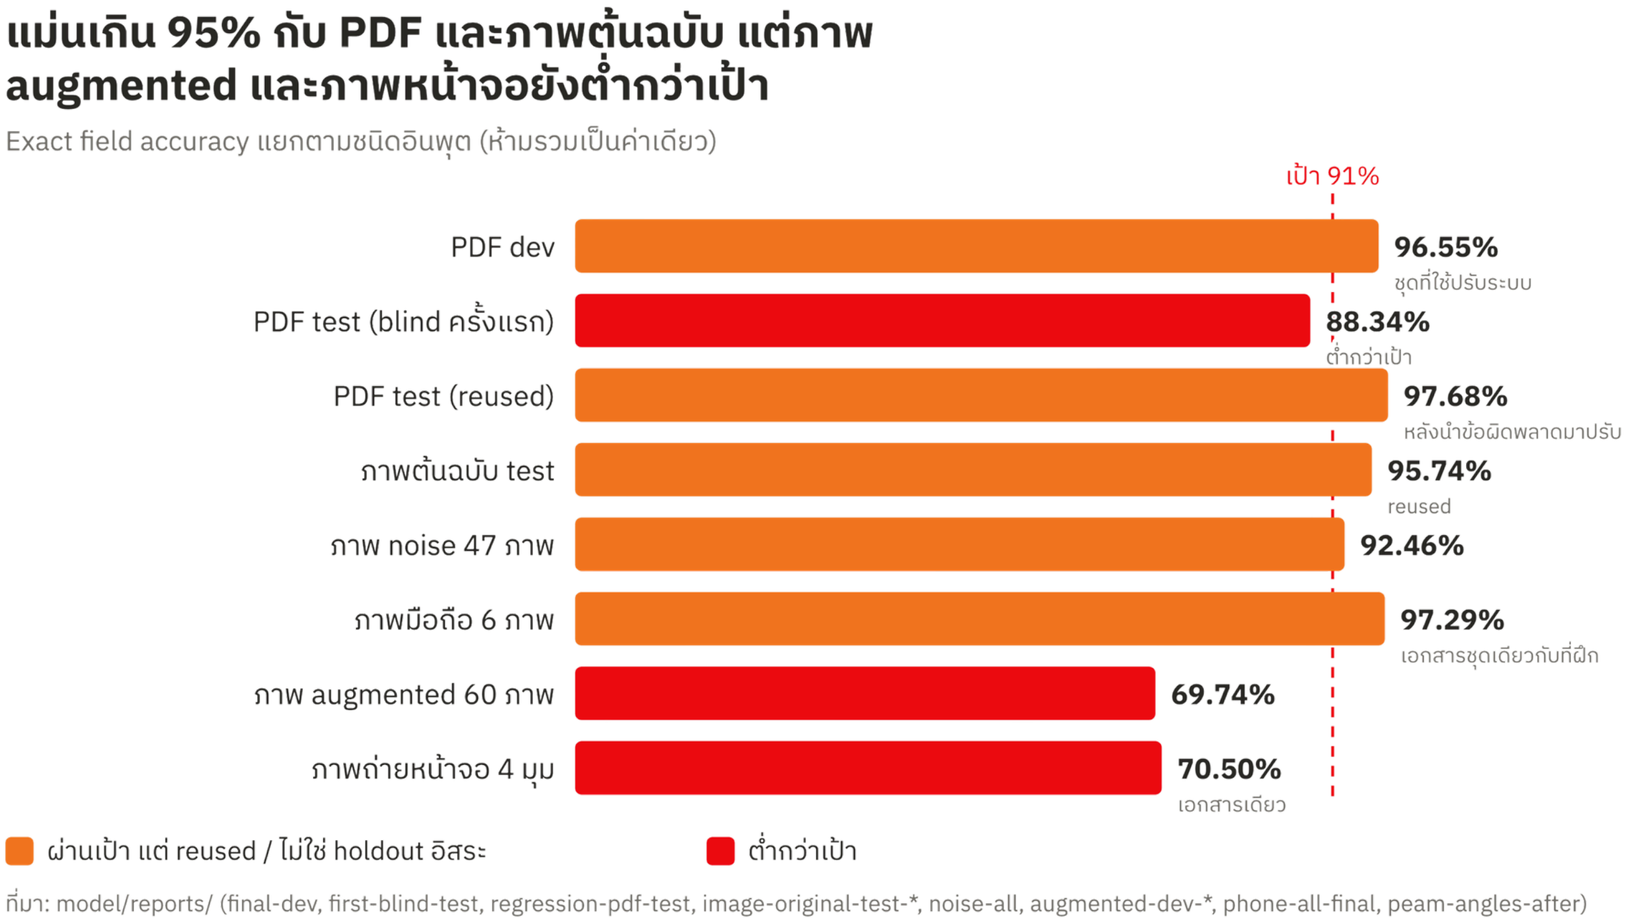


transcript จริง 48 ฉบับ · 47 ฉบับมีเฉลย · แบ่งตามเอกสารต้นทาง (ภาพที่มาจากเอกสารเดียวกันอยู่ชุดเดียวกัน)

Metric หลัก: exact field accuracy · เสริม: row F1, CER, latency · เป้า: accuracy > 91%, เวลาเฉลี่ย < 30 วินาที/ฉบับ

ที่มา: docs/process.md (Decision Log), model/data/manifest.json

ความแม่นยำแยกตามชนิดอินพุต

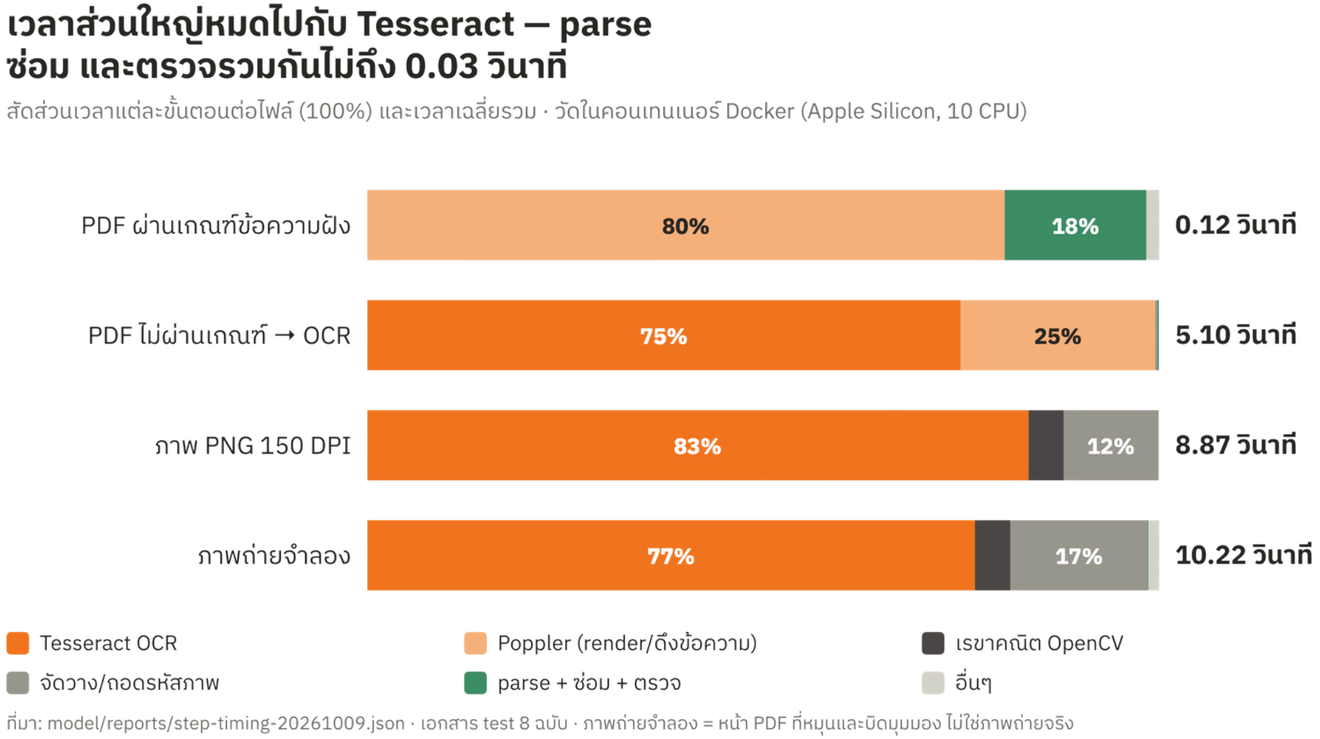


ผ่านเป้า: PDF, ภาพต้นฉบับ, ภาพ noise, ภาพมือถือ
ต่ำกว่าเป้า: ภาพ augmented 69.74% · ภาพหน้าจอ 70.50% · test ครั้งแรก (blind) 88.34% ไม่ผ่าน → ปรับแล้ว reused 97.68%

ระยะเวลาที่ใช้ (รายขั้นตอน)

รูปแบบ	เวลา
ปริญญาตรี ไทย	11.04 วินาที
บัณฑิตศึกษา ไทย	15.96 วินาที
ปริญญาตรี อังกฤษ	4.15 วินาที
บัณฑิตศึกษา อังกฤษ	4.33 วินาที

Tesseract ใช้ 75 – 85% ของเวลา · ผ่านระบบจริงทั้งชุด 12 PDF มัธยฐาน 0.078 วินาที

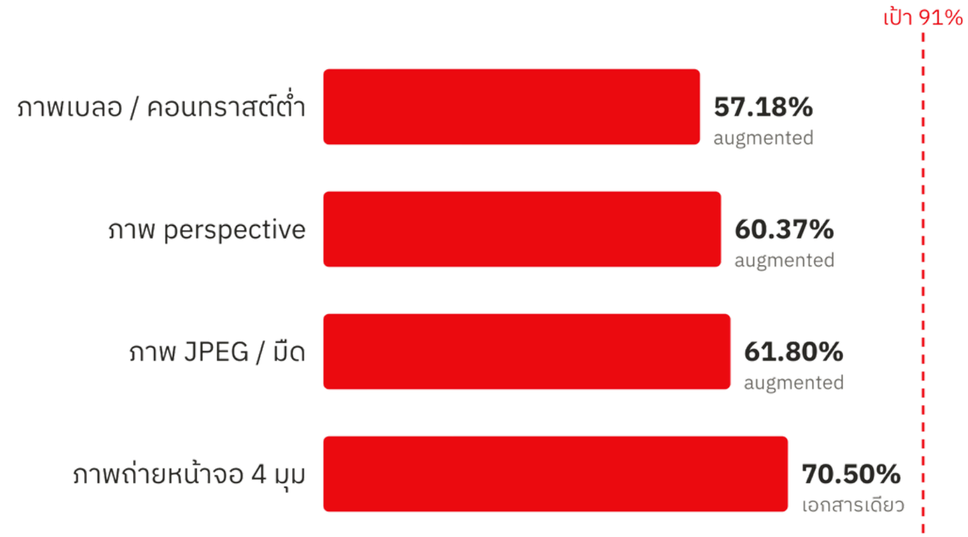


ข้อจำกัดและที่จะทำต่อ

ข้อจำกัด	ตัวเลข	สิ่งที่รู้แล้ว	ที่ระบบทำให้ตอนนี้ / ทำต่อ
ภาพเบลอ / คอนทราสต์ต่ำ	57.18%	แก้เอียง (deskew) ไม่ช่วยกลุ่มนี้, ลองปรับภาพและโหมด OCR เพิ่มแล้วผลไม่สม่ำเสมอ จึงไม่เปิดใช้	เก็บภาพเบลอเพิ่มเพื่อวิเคราะห์ข้อผิดพลาดรายภาพ (ยังไม่ได้แยกสาเหตุ)
ภาพ JPEG / มือ	61.80%	deskew ไม่ช่วยกลุ่มนี้ · ยังไม่ได้แยกสาเหตุ	วิเคราะห์ข้อผิดพลาดรายภาพ
ภาพมือถือยังผิด	24/885 ฟิลด์	ผิดที่ชื่อวิชา 13 · วันที่ 4 · เกรด 3 · ชื่อคน 2 · คำนำหน้า 1 · รหัสวิชา 1 — ส่วนรหัสนักศึกษา 6/6 และ GPA สะสม 6/6 ถูกหมด	ระบบเตือน "กรุณาเทียบกับภาพก่อนบันทึก" ทุกครั้งที่อ่านภาพถ่ายมือถือ
ยังไม่มีเอกสารใหม่ล้วนมาทดสอบ	dev/test ถูกใช้ปรับระบบแล้ว	เก็บเอกสารใหม่เป็น holdout, ลดเวลา OCR ของเอกสารไทย	เก็บเอกสารใหม่เป็น holdout อิสระ ก่อนอ้างความแม่นยำทั่วไป

ยังอ่านภาพเบลอ/มือ/เอียงแรงไม่ดี ต่ำกว่าเป้า 91%

กลุ่มภาพที่ยังไม่ผ่านเป้า (exact field accuracy)



ภาพมือถือ: ผิด 24/885 ฟิลด์ — ชื่อวิชา 13 · วันที่ 4 · เกรด 3 · ชื่อคน 2 · คำนำหน้า 1 · รหัสวิชา 1

ที่มา: model/reports/augmented-dev-deskew-full-20261004.json, peam-angles-after-20261004.json, phone-all-final-20261007.json

เริ่มใช้งานใน 4 ขั้นตอน

ขั้นตอน	คำสั่ง
1	ติดตั้งและเปิด Docker Desktop
2	git clone https://github.com/PoohParamour/isd-2026-loso.git
3	docker compose up --build
4	เปิด http://localhost:3000/upload

WORKSPACE

↑ นำเข้า Transcript

ค้นหาผลการเรียน

เอกสารในรอบนี้

ยังไม่มีเอกสาร

นำเข้า Transcript

เลือกไฟล์จากอุปกรณ์ หรือถ่ายภาพเอกสารเพื่ออ่านเข้าสู่ระบบ

↑

วางไฟล์ Transcript ที่นี่

รองรับ PDF, JPG, PNG, TIFF และ HEIC · สูงสุด 20 MB ต่อไฟล์ · เลือกได้หลายไฟล์

เลือกไฟล์จากอุปกรณ์ | เปิดกล้องเพื่อถ่ายรูป

รูปแบบเอกสาร

ตรวจรูปแบบอัตโนมัติ

☐ บังคับอ่านด้วย OCR (สำหรับ PDF สแกน)

เพื่อให้ OCR อ่านได้แม่นยำ

แนะนำก่อนเลือกไฟล์

- ใช้ PDF ต้นฉบับเป็นตัวเลือกแรก
- ภาพต้องคม ชัด และอ่านตัวอักษรได้
- ไม่เอียง ไม่กลับหัว และไม่ครอปข้อมูล
- หลีกเลี่ยงเงาและแสงสะท้อน

ดู checklist ฉบับเต็ม →

ต้องการความช่วยเหลือ?

คู่มือถ่ายเอกสารให้ OCR อ่านแม่นยำ

เปิดคู่มือ →

WORKSPACE

↑ นำเข้า Transcript

ค้นหาผลการเรียน

เอกสารในรอบนี้

ยังไม่มีเอกสาร

ค้นหาผลการเรียน

นักศึกษาที่บันทึกไว้ในฐานข้อมูล คลิกที่รายชื่อเพื่อดูผลการเรียนรายวิชา

กรองด้วยรหัสนักศึกษาหรือชื่อ

เช่น 67070127 หรือ ชื่อ

แสดง 6 จาก 6 คน

ค้นตามรหัสวิชา (ไม่บังคับ)

เช่น 01006001

ตัวเลข 8 หลัก

ค้นวิชา

รหัสนักศึกษา	ชื่อ - นามสกุล	คณะ	หลักสูตร	รายวิชา	GPA สะสม	บันทึกล่าสุด
67070005	Mr. Kaweewat Sanonkullawat	—	Data Science and Business An...	32	**2.55**	9 ต.ค. 2569 21:43
67070124	Mr. Pakaphon Phothivorn	—	Data Science and Business An...	32	**3.59**	4 ต.ค. 2569 17:38 · 2 ฉบับ
71030001	นาย คอ1 ครุศาสตร์อุตสาหกรรมและเทคโนโลยี1	คณะครุศาสตร์อุตสาหกรร...	เทคโนโลยีอิเล็กทรอนิกส์	27	**1.47**	4 ต.ค. 2569 14:28
71020009	ปริญญา สถาบัตยกรรมศาสตรบัณฑิต	คณะสถาปัตยกรรมศิลปะแ...	ศิลปอุตสาหกรรม	56	**2.07**	4 ต.ค. 2569 14:28
71020001	—	คณะสถาปัตยกรรมศิลปะแ...	ภูมิสถาปัตยกรรม	46	**2.45**	4 ต.ค. 2569 14:28
67070127	Mr. Pattarapol Petcharat	—	Data Science and Business An...	30	**2.42**	4 ต.ค. 2569 14:04 · 4 ฉบับ

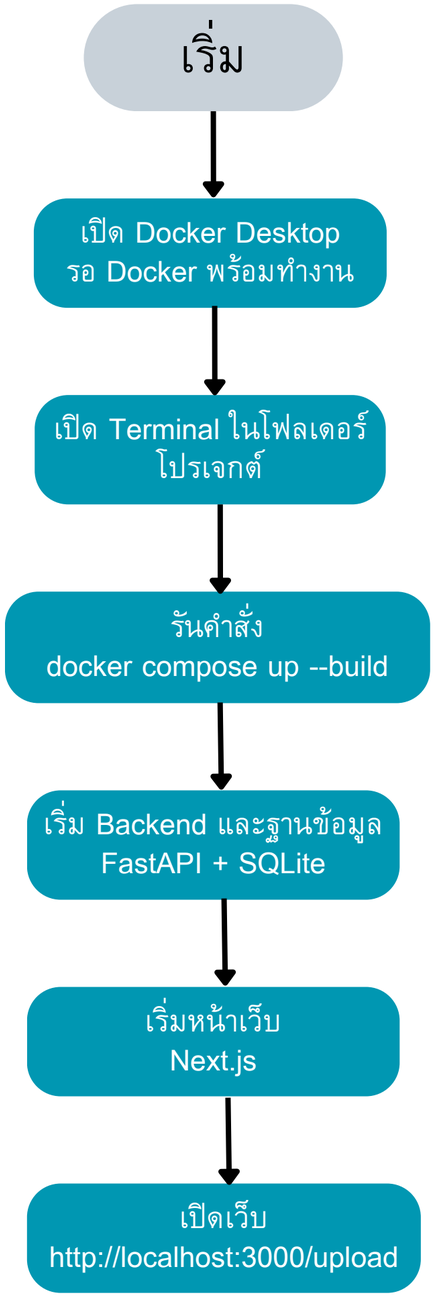
ต้องการความช่วยเหลือ?

คู่มือถ่ายเอกสารให้ OCR อ่านแม่นยำ

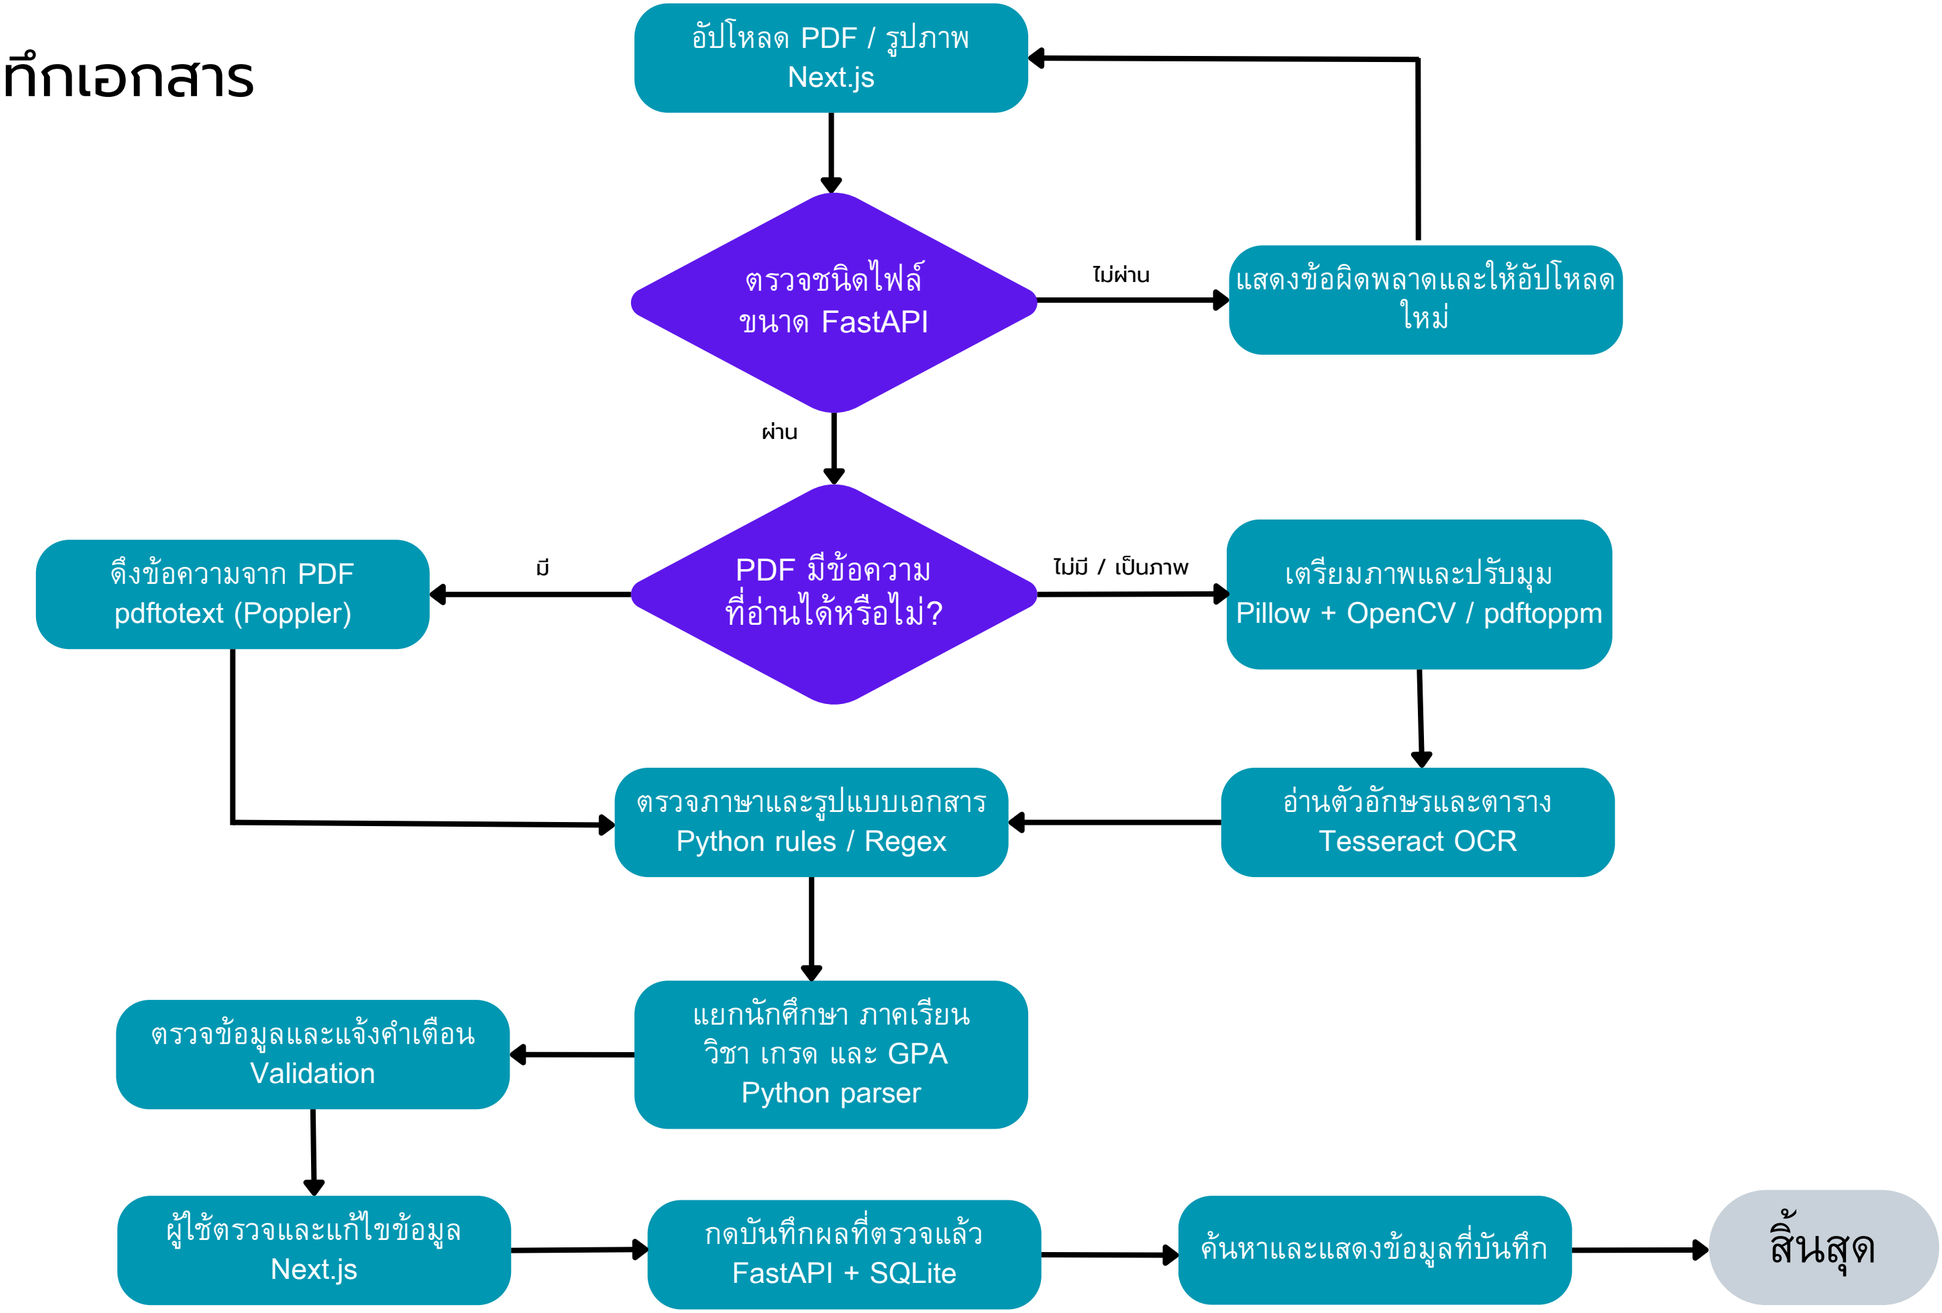
เปิดคู่มือ →

Flowchart s:uu OCR Transcript

การเริ่มระบบ


เริ่ม
เปิด Docker Desktop
รอ Docker พร้อมทำงาน
เปิด Terminal ในโฟลเดอร์โปรเจกต์
รันคำสั่ง
docker compose up --build
เริ่ม Backend และฐานข้อมูล
FastAPI + SQLite
เริ่มหน้าเว็บ
Next.js
เปิดเว็บ
http://localhost:3000/upload

การอ่านและบันทึกเอกสาร



ผลทดสอบทุกชุด แยกตามชนิดไฟล์ และบอกว่าชุดไหนเคยใช้ปรับระบบแล้ว

T1 ผลหลัก (สถานะ: เขียว = ผ่านเป้า · ส้ม = ผ่านเป้า แต่ชุดนี้เคยใช้ปรับระบบแล้ว · แดง = ต่ำกว่าเป้า 91%)

blind = ทดสอบครั้งแรกก่อนแก้ระบบ · reused = ทดสอบซ้ำกับชุดเดิมหลังแก้ระบบแล้ว

ชุดอินพุต	ถูก/ทั้งหมด	Exact field	Row F1	เวลาเฉลี่ย (วินาที)	สถานะ
PDF dev 35 ฉบับ	4394/4551	96.55%	—	—	ชุดที่ใช้ปรับระบบ
PDF test ครั้งแรก	1182/1338	88.34%	—	—	blind (ครั้งแรก) ไม่ผ่านเป้า
PDF test หลังปรับระบบ	1307/1338	97.68%	—	—	reused (ทดสอบซ้ำ)
ภาพต้นฉบับ PNG 150 DPI (test 12 ฉบับ)	1281/1338	95.74%	100%	9.42	reused (ทดสอบซ้ำ)
ภาพ noise 47 ภาพ	5445/5889	92.46%	98.10%	12.18	รวมชุด dev และ test
ภาพ augmented ผสม 60 ภาพ	4373/6270	69.74%	82.55%	14.22 (สูงสุด 44.33)	ต่ำกว่าเป้า
ภาพมือถือ HEIC 6 ภาพ	861/885	97.29%	99.46%	27.54 (สูงสุด 28.64)	เป็นเอกสารเดียวกับที่ใช้ฝึก
ภาพถ่ายหน้าจอ 4 มุม (เอกสารเดียว)	423/600	70.50%	76.03%	30.90	ต่ำกว่าเป้า ทดสอบเอกสารเดียว

T2 ภาพต้นฉบับแยกกลุ่มเอกสาร

รูปแบบ	ถูก/ทั้งหมด	Exact field
ปริญญาตรี ไทย	358/384	**93.23%**
ปริญญาตรี อังกฤษ	340/347	**97.98%**
บัณฑิตศึกษา ไทย	286/300	**95.33%**
บัณฑิตศึกษา อังกฤษ	297/307	**96.74%**

T3 ภาพ augmented แยกความเสียหาย

ความเสียหาย	ก่อน deskew	หลัง deskew
หมุน / ปรับสว่าง	61.80%	**74.80%**
perspective	56.22%	**60.37%**
noise	94.58%	**94.58%**
บัณฑิตศึกษา อังกฤษ	297/307	**96.74%**
JPEG / มืด	61.80%	**61.80%**

โมเดลอ่านภาพที่รันในเครื่อง (Local VLM) ช้าและแม่นน้อย จึงไม่ใช้เป็นวิธีหลัก

T1 ตั้งค่าการทดลอง

หัวข้อ	ค่า
โมเดล	scb10x/typhoon-ocr1.5-3b → qwen3:4b (Ollama ในเครื่อง)
อินพุต	ภาพ PNG 150 DPI จากชุด dev
จำนวน	4 ฉบับ (รูปแบบละ 1)
เวลาสูงสุดที่รอ (timeout)	120 วินาที ในขั้นอ่านภาพ
ค่า API	0 USD

T2 ผลแต่ละรูปแบบ

รูปแบบ	ผล	เวลา
ปริญญาตรี ไทย	สำเร็จ แต่ถูก 1/75 ฟิลด์ (1.33%)	**121.1 วินาที**
ปริญญาตรี อังกฤษ	timeout	**> 120 วินาที**
บัณฑิตศึกษา ไทย	timeout	**> 120 วินาที**
บัณฑิตศึกษา อังกฤษ	timeout	**> 120 วินาที**

วิธี	Exact field	เวลาเฉลี่ย	ชุดข้อมูล
Hybrid	98.26%	**0.43 วินาที**	**PDF 8 ฉบับ**
Local VLM	1.33%	**121.1 วินาที**	**ภาพ PNG 4 ฉบับ (คนละชุดกับ Hybrid)**

T3 เทียบกับวิธีที่ระบบใช้งานจริง (Hybrid)

ฝึก OCR เพิ่มด้วยภาพมือถือ ทำให้อ่านผิดน้อยลงมาก แต่ยังทดสอบกับเอกสารชุดเดิมเท่านั้น

T1 การแบ่งข้อมูล (ภาพมือถือ HEIC 6 ภาพ = 2 เอกสาร × 3 มุม)

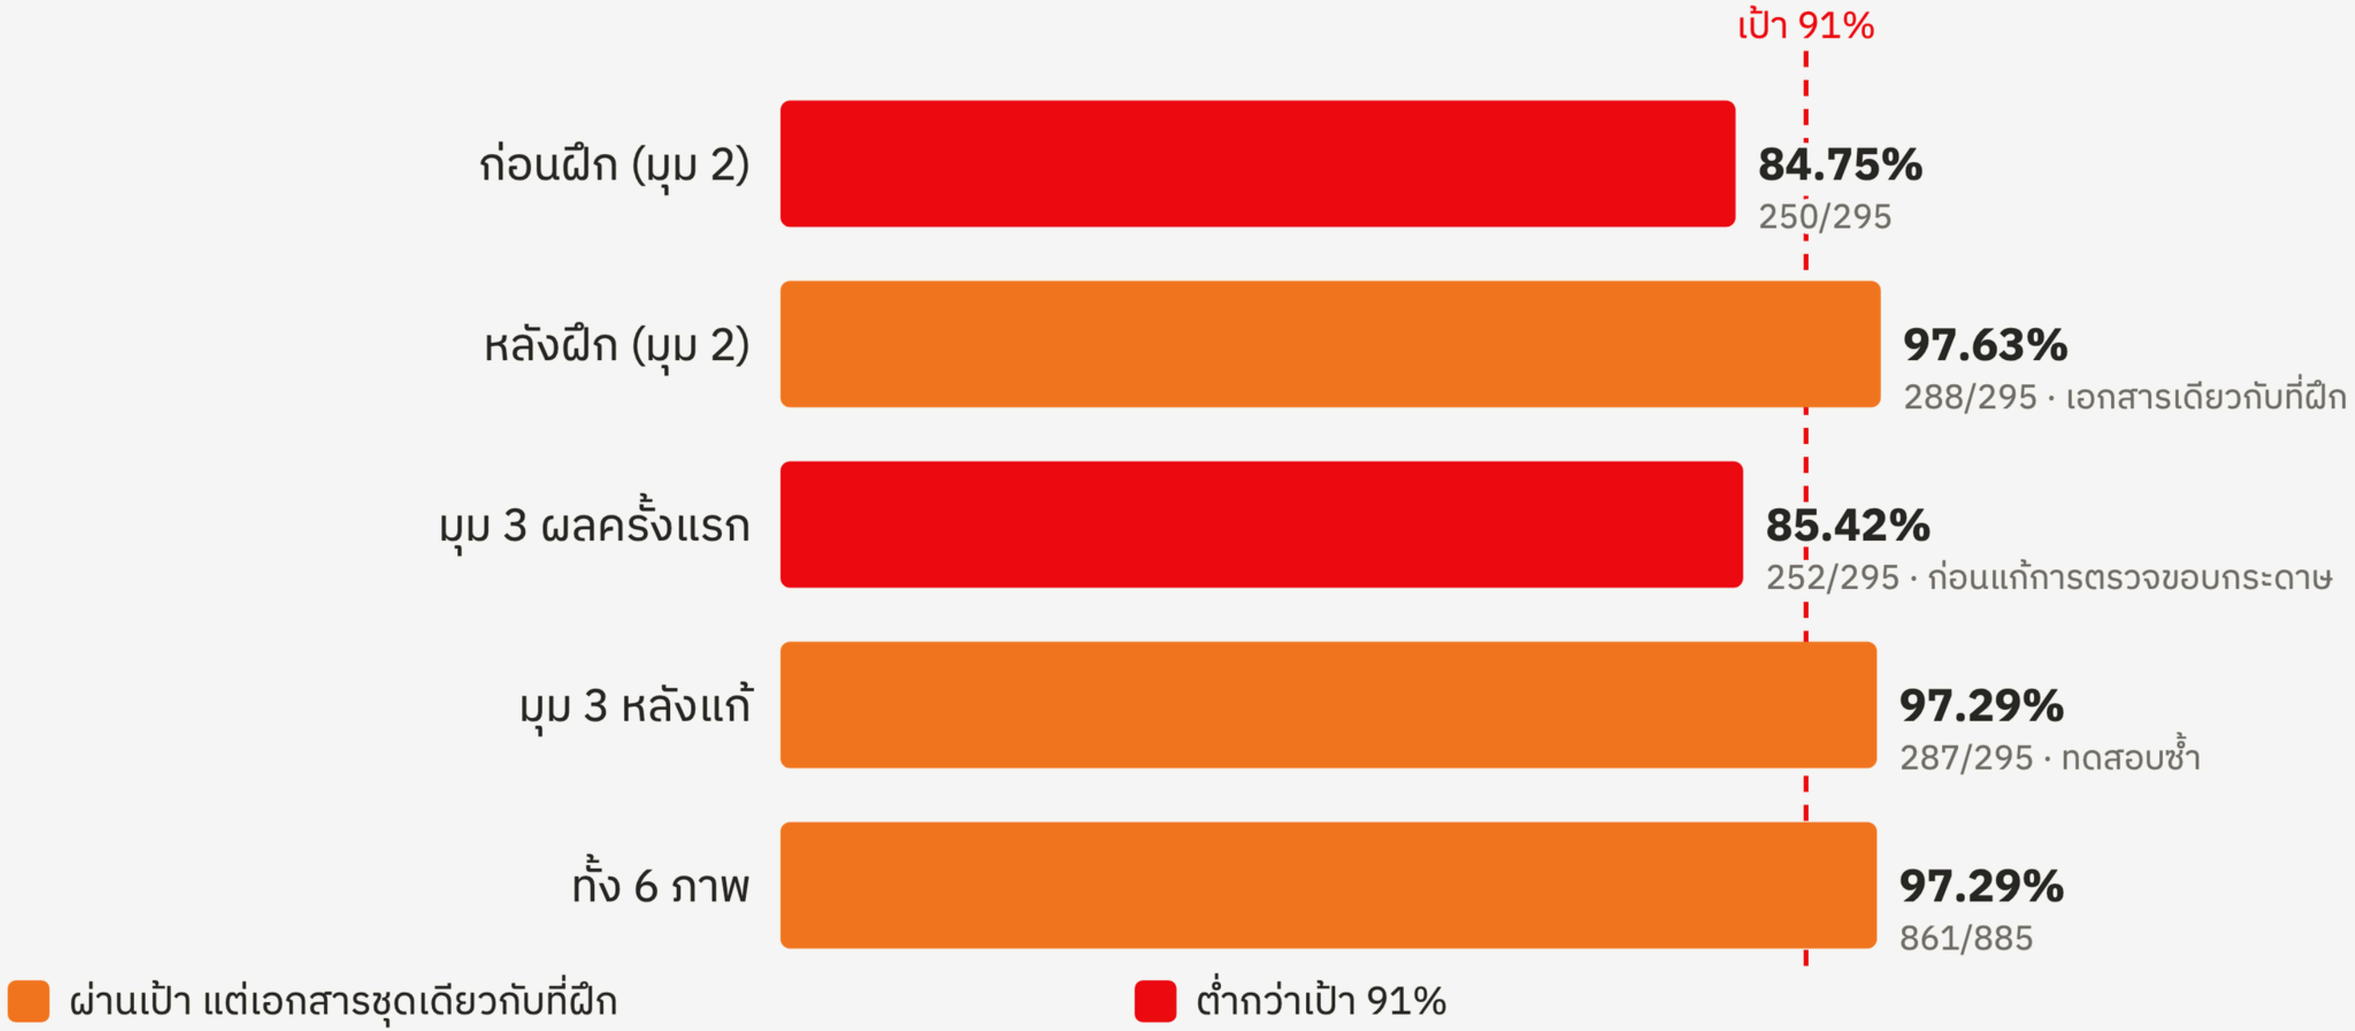
มุม	บทบาท	ข้อมูล
1	ฝึก	109 บรรทัด
2	ตรวจ / เลือกค่า	109 บรรทัด (2 ภาพ · 295 ฟิลด์)
3	ทดสอบสุดท้าย (เก็บไว้ ไม่ใช้ฝึก)	2 ภาพ · 295 ฟิลด์

T2 การลองชุดค่า (CER = อัตราอ่านผิดต่อตัวอักษร ยิ่งต่ำยิ่งดี · ก่อนฝึก: Tesseract ตัวที่ติดตั้ง 8.83% · โมเดลที่ฝึกจากภาพรุ่นก่อน 7.86%)

จำนวนรอบฝึก (iterations)	learning rate	CER บนชุดตรวจ	ผล
100	0.0001	**6.17%**	
300	0.0001	**2.31%**	**เลือก**
600	0.0001	**2.49%**	
300	0.0003	**2.31%**	**เท่ากับที่เลือก ไม่ได้ดีกว่า**

ฝึก OCR เพิ่มแล้วอ่านแม่นขึ้น แต่ยังทดสอบกับเอกสารชุดเดิมเท่านั้น

ภาพมือถือ 6 ภาพ (2 เอกสาร × 3 มุม) · ความแม่นยำระดับฟิลด์ (exact field accuracy)



ที่มา: model/reports/phone-training-summary-20261007.json

ตัดเอกสารที่วัดออกจากพจนานุกรมรายวิชา (catalog) ผลลดลงแค่ 2.3 จุด แต่ยังไม่ใช่การทดสอบกับเอกสารใหม่จริงๆ

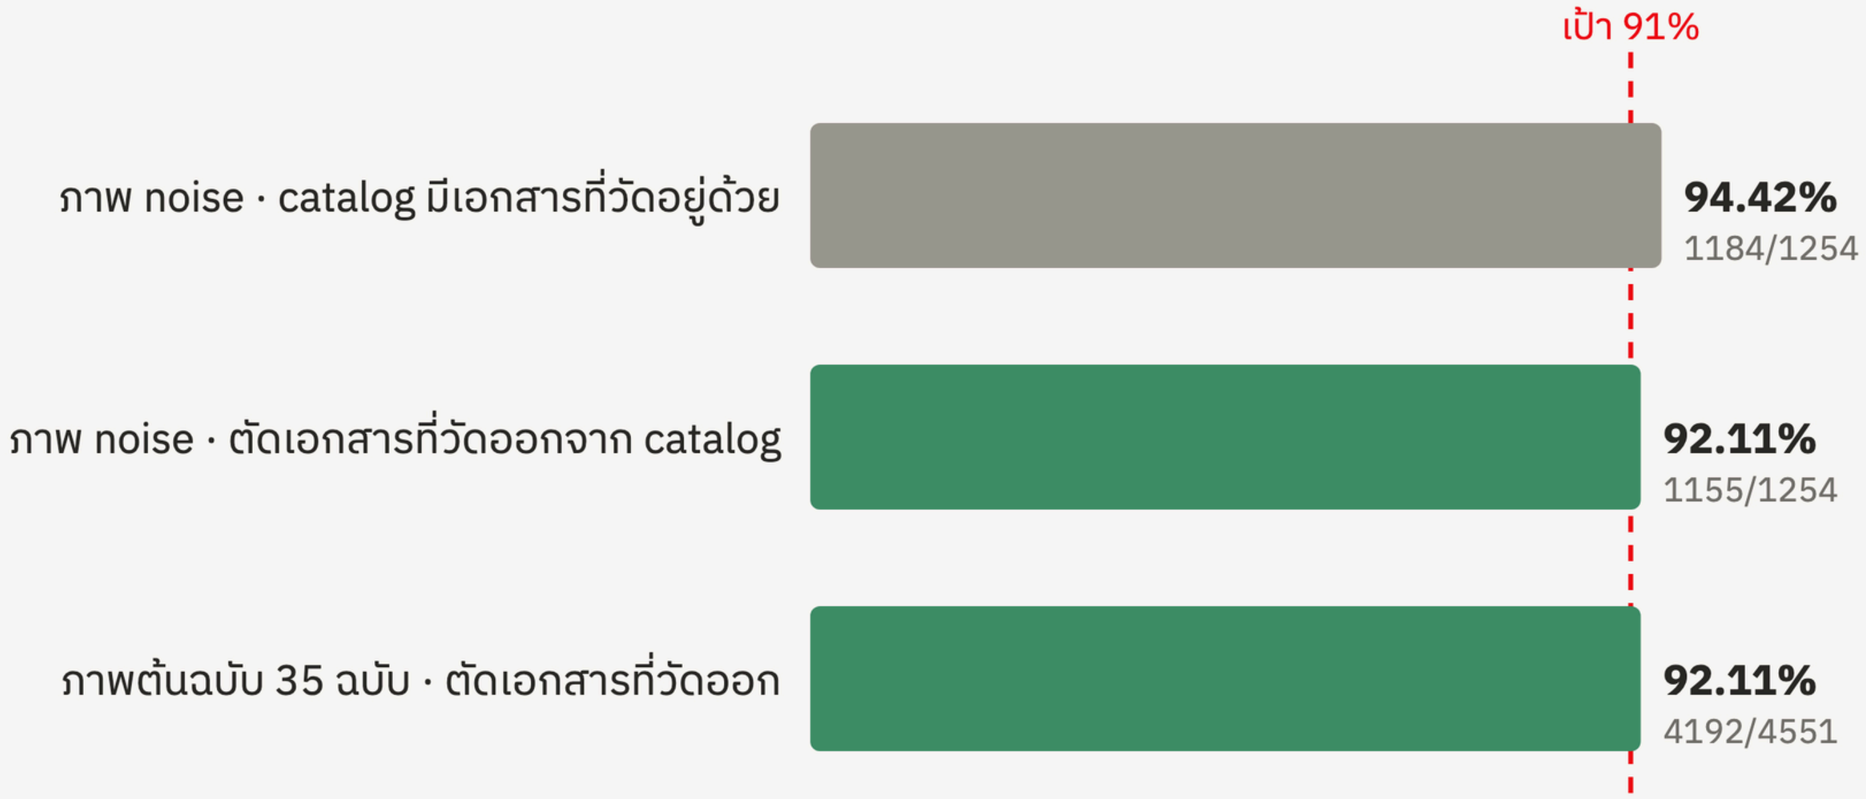
T1 ทำอะไรไปแล้ว / อะไรที่ยังเป็นข้อจำกัด

มาตรการ	สถานะ	หมายเหตุ
catalog รหัสวิชา/หัวข้อ สร้างจากชุด dev เท่านั้น	ทำแล้ว	**ไม่ใช้ชุด test**
วัดซ้ำโดยตัดเอกสารที่กำลังวัดออกจาก catalog ทั้งฉบับ	ทำแล้ว	**model/tools/ benchmark_catalog_cv.py**
ไม่ใช้เฉลยหรือชื่อไฟล์ตอนอ่าน (inference)	ทำแล้ว	**parse ด้วยกฎล้วน**
ตัวแปลงข้อมูลและกฎซ่อมเคยปรับบนชุด dev	ข้อจำกัด	**จึงยังไม่ใช่การทดสอบกับเอกสารใหม่จริงๆ**

Footnote: noise-dev-term-fix.json (94.42% catalog มีเอกสารที่วัดอยู่ด้วย), noise-dev-catalog-held-out.json (92.11% ตัดเอกสารที่วัดออก), original-dev-catalog-held-out-all.json (92.11% ตัดเอกสารที่วัดออก)

ตัดเอกสารที่วัดออกจาก catalog แล้ว ผลลดลงแค่ 2.3 จุด

catalog = พจนานุกรมรหัสวิชา/ชื่อวิชาที่ใช้ซ่อมข้อความ OCR · ความแม่นยำระดับฟิลด์



ตัดเอกสารที่วัดออกจาก catalog ผลลดลงแค่ 2.3 จุด (94.42 → 92.11)

ยังไม่ใช่การทดสอบกับเอกสารใหม่จริงๆ เพราะกฎซ่อมเคยปรับบนชุด dev

ที่มา: model/reports/noise-dev-term-fix.json, noise-dev-catalog-held-out.json, original-dev-catalog-held-out-all.json

เฉลยบางจุดไม่ตรงกับเอกสารจริง จึงรายงานคะแนนทั้งแบบตามเฉลยเดิมและแบบตามเอกสาร

T1 เฉลยที่ไม่ตรงกับเอกสาร (test 12 ฉบับ)

ประเภท	จำนวนฟิลด์
วันที่ออกเอกสาร (footer_detail.updated_at) ไม่ตรงภาพ	10
ฟิลด์ของภาคสุดท้ายที่ไม่ปรากฏในเอกสาร	12
หน่วยกิตรวมไม่ตรง	1
รวม	2

T2 คะแนนแต่ละวิธีคิด (รุ่นปัจจุบัน)

วิธีคิด	ถูก/ทั้งหมด	Exact field
ตามเฉลยเดิม (raw)	1281/1338	95.74%
ไม่นับฟิลด์ที่เฉลยไม่ตรงทั้ง 23 ฟิลด์ (นับเฉพาะที่เฉลยถูก)	1281/1315	97.41%
ตามเอกสารที่มองเห็น (เพิ่ม 11 ค่าที่ OCR ตรงเอกสาร ตัด 12 ฟิลด์ที่ไม่มีในเอกสาร)	1292/1326	97.44%
วิธีคิด	ถูก/ทั้งหมด	Exact field

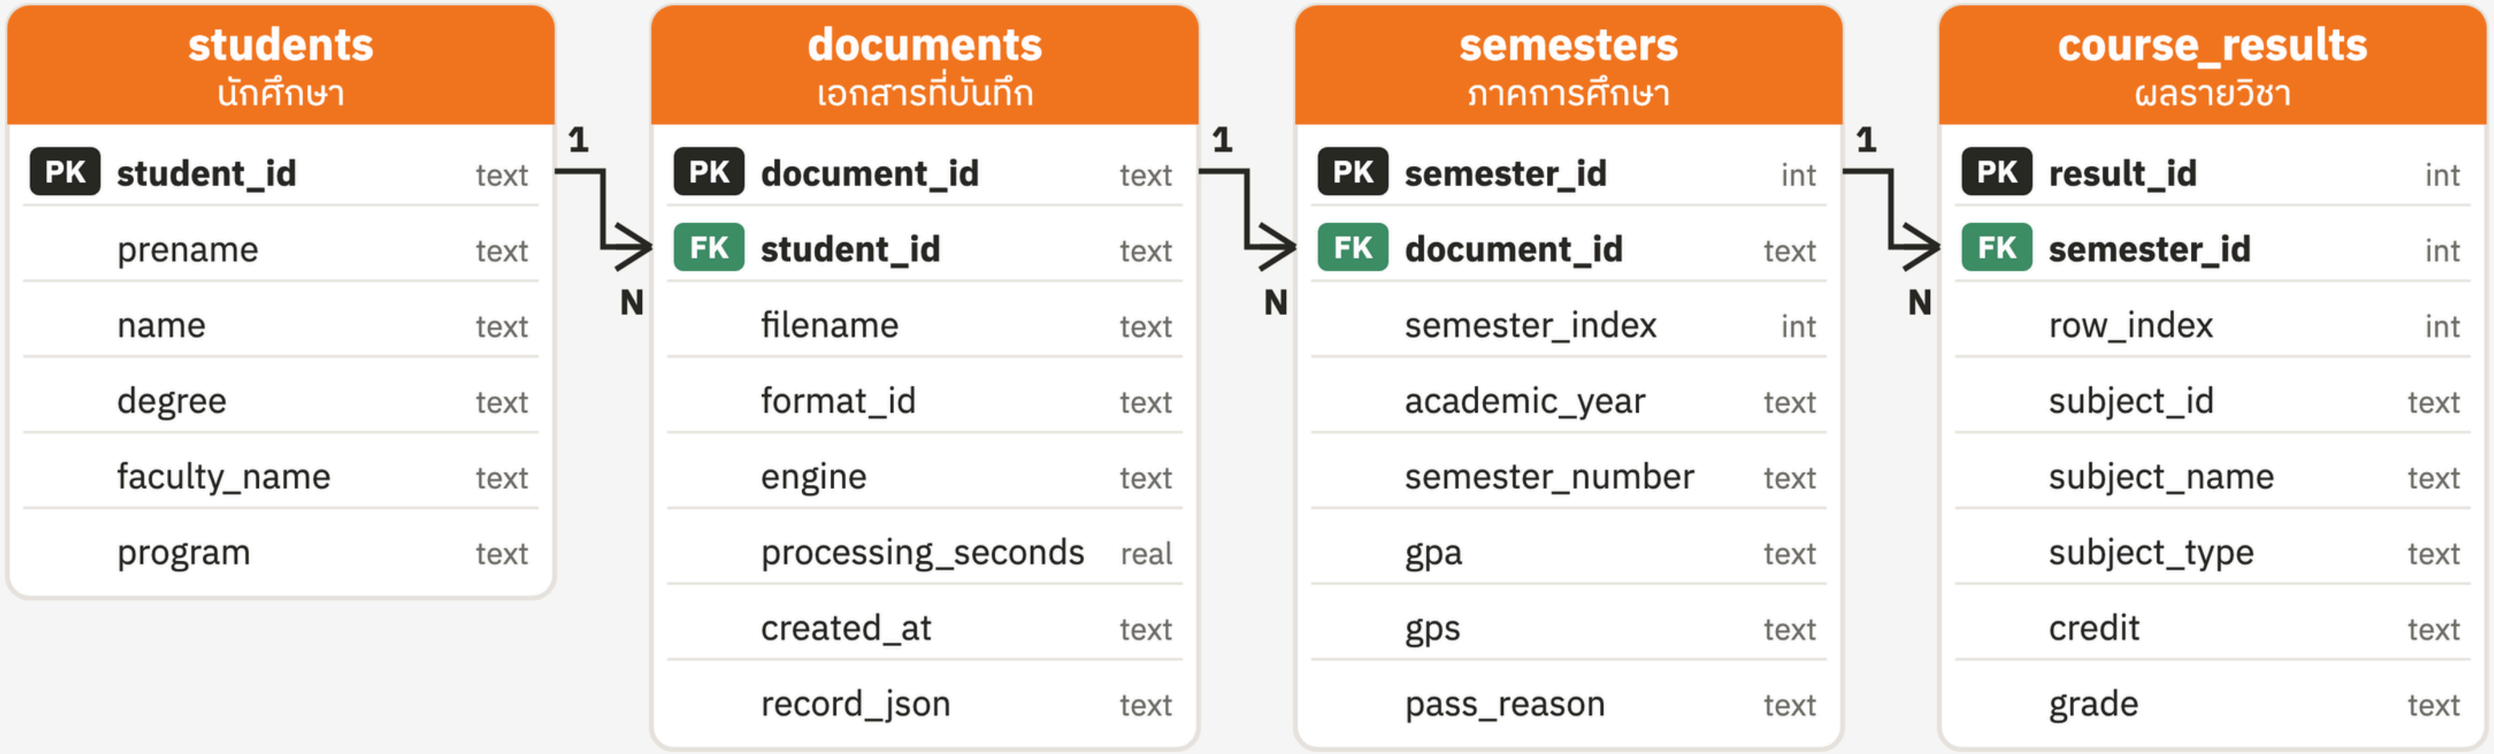
API 8 endpoint และฐานข้อมูล SQLite 4 ตาราง

T1 API

Method	Path	ใช้ทำอะไร
POST	/api/transcripts/extract	**อัปโหลดไฟล์ → ผล OCR + validation**
POST	/api/validate	**ตรวจข้อมูลซ้ำหลังผู้ใช้แก้**
POST	/api/documents	**บันทึกผลที่ตรวจแล้ว**
GET	/api/documents/{id}	**เปิดเอกสารที่บันทึกไว้**
GET	/api/students	**รายชื่อนักศึกษา (ฉบับล่าสุดของแต่ละคน)**
GET	/api/grades? student_id=&subject_id=	**ผลรายวิชา**
GET	/api/suggest?kind=&q=	**รายการแนะนำรหัส**
GET	/api/health	**สถานะ (Tesseract, pdftotext, รูปแบบเอกสาร)**

ฐานข้อมูล: นักศึกษา 1 คน มีหลายเอกสาร → หลายภาค → หลายรายวิชา

SQLite 4 ตาราง · foreign key เปิดใช้ (PRAGMA foreign_keys = ON)



PK = คีย์หลัก

FK = คีย์อ้างอิง (foreign key)

ลบเอกสาร → ภาคและรายวิชาถูกลบตาม (cascade) · index: course_results(subject_id), documents(student_id)

ที่มา: backend/app/database.py

เมื่อต้อง OCR เวลา 75–85% หมดไปกับ Tesseract ส่วนแปลงข้อมูล ซ่อม และตรวจสอบรวมกันใช้ไม่ถึง 0.03 วินาที

T1 เวลาแต่ละกรณี

กรณี	เฉลี่ย	ช่วง (ต่ำสุด–สูงสุด)	ขั้นที่ใช้เวลามากสุด
PDF ผ่านเกณฑ์ข้อความฝัง	0.12 วินาที	**0.04–0.62**	**pdftotext 80%**
PDF ไม่ผ่านเกณฑ์ → OCR	5.10	**3.20–7.45**	**Tesseract 75% · Poppler render 24%**
PDF บังคับ OCR (8 ฉบับ × 2)	8.68	**1.19–34.58**	**Tesseract 85% · Poppler render 14%**
ภาพ PNG 150 DPI (8 ฉบับ × 2)	8.87	**3.52–18.51**	**Tesseract 84%**
ภาพถ่ายจำลอง (2 ฉบับ × 2)	10.22	**6.14–14.44**	**Tesseract 77% · จัดวาง 12%**

เมื่อต้อง OCR เวลา 75–85% หมดไปกับ Tesseract ส่วนแปลงข้อมูล ซ่อม และตรวจสอบ รวมกันใช้ไม่ถึง 0.03 วินาที

T3 เวลาแยกรูปแบบเอกสาร (ภาพ PNG ฉบับละ 2 รอบ)

รูปแบบ	เวลาเฉลี่ย
ปริญญาตรี ไทย	**11.04 วินาที**
บัณฑิตศึกษา ไทย	**15.96 วินาที**
ปริญญาตรี อังกฤษ	**4.15 วินาที**
บัณฑิตศึกษา อังกฤษ	**4.33 วินาที**